

## **Machine Learning from Data – IDC**

### **HW5 – Support VectorsMachine**

Theoretical  
questions:

1. Use Lagrange Multipliers to find the maximum and minimum values of the function subject to the given constraints:

a.  $f(x, y) = e^{xy}$ ; constraint:  $2x^2 + y^2 = 72$

$$L(x, y) = e^{xy} + \lambda(2x^2 + y^2 - 72) = 0$$

$$\nabla_x \rightarrow L(x, y) = ye^{xy} + 4\lambda x = 0 \rightarrow ye^{xy} = -4\lambda x$$

$$\nabla_y \rightarrow L(x, y) = xe^{xy} + 2\lambda y = 0 \rightarrow xe^{xy} = -2\lambda y$$

נחלק את המשוואה הראשונה בשנייה ונקבל:

$$\frac{ye^{xy}}{xe^{xy}} = \frac{-4\lambda x}{-2\lambda y} \rightarrow \frac{y}{x} = \frac{2x}{y} \rightarrow y^2 = 2x^2$$

$$\nabla \lambda \rightarrow L(x, y) = 2x^2 + y^2 - 72 = 0$$

אז נציב במשוואה השלישית ונקבל:

$$y^2 + y^2 - 72 = 0 \rightarrow 2y^2 = 72 \rightarrow y^2 = 36 \rightarrow y = \pm 6$$

$$y = 6 \rightarrow 36 = 2x^2 \rightarrow x = \pm\sqrt{18}$$

לכן:

$$f(x, y) = e^{xy}$$

$$f(6, \sqrt{18}) = e^{6\sqrt{18}}$$

$$f(6, -\sqrt{18}) = e^{-6\sqrt{18}}$$

$$f(-6, \sqrt{18}) = e^{-6\sqrt{18}}$$

$$f(-6, -\sqrt{18}) = e^{6\sqrt{18}}$$

$$\max = e^{6\sqrt{18}}, \min = e^{-6\sqrt{18}}$$

b.  $f(x, y) = x^2 + y^2$ ; constraint:  $y - \cos 2x = 0$

$$L(x, y) = x^2 + y^2 + \lambda(y - \cos 2x) = 0$$

$$\nabla_x \rightarrow L(x, y) = 2x + 2\lambda \sin 2x = 0 \rightarrow x = -\lambda \sin 2x$$

$$\nabla_y \rightarrow L(x, y) = 2y + \lambda = 0 \rightarrow 2y = -\lambda$$

$$\nabla_\lambda \rightarrow L(x, y) = y - \cos 2x = 0 \rightarrow y = \cos 2x$$

נחלק את המשוואה הראשונה בשנייה ונקבל:

$$\frac{x}{2y} = -\frac{\lambda \sin 2x}{-\lambda} \rightarrow \frac{x}{2y} = \sin 2x$$

נציב את המשוואה שלישית בזאת ונקבל:

$$\frac{x}{2\cos 2x} = \sin 2x \rightarrow x = 2\sin 2x \cos 2x \rightarrow 2x = 4\sin 2x \cos 2x \rightarrow 2x = \sin 4x \rightarrow$$

$$x = 0, 0.619, -0.619$$

$$x = 0 \rightarrow y = \cos 2x \rightarrow y = \cos 0 = 1$$

$$x = 0.619 \rightarrow y = \cos(2 * 0.619) = \cos 1.238 = 0.326$$

$$x = -0.619 \rightarrow y = \cos(2 * -0.619) = \cos -1.238 = 0.326$$

$$f(x, y) = x^2 + y^2$$

$$f(0, 1) = 0 + 1 = 1$$

$$f(0.619, 0.326) = (0.619)^2 + (0.326)^2 = 0.383 + 0.106 = 0.489$$

$$f(-0.619, 0.326) = (0.619)^2 + (0.326)^2 = 0.383 + 0.106 = 0.489$$

$$\min = 0.489, \quad \max = 1$$

2.

a. Consider two kernels  $K_1$  and  $K_2$ , with the mappings  $\varphi_1$  and  $\varphi_2$  respectively. Show that  $K = 7K_1 + 3K_2$  is also a kernel and find its corresponding  $\varphi$ .

יהיו  $x, y$  וקטורים במרחב כלשהו, לפני המיפוי ויהיו  $d_1, d_2$  מימדים ממימד כלשהו לאחר המיפוי אז לפי ההגדרה של קרנל:

$$K_1(x, y) = \varphi_1(x) \cdot \varphi_1(y) = \sum_{i=1}^{d_1} \varphi_1(x)_i \cdot \varphi_1(y)_i$$

$$K_2(x, y) = \varphi_2(x) \cdot \varphi_2(y) = \sum_{i=1}^{d_2} \varphi_2(x)_i \cdot \varphi_2(y)_i$$

ולכן:

$$K(x, y) = 7K_1(x, y) + 3K_2(x, y) = 7 \sum_{i=1}^n \varphi_1(x)_i \cdot \varphi_1(y)_i + 3 \sum_{i=1}^m \varphi_2(x)_i \cdot \varphi_2(y)_i =$$

$$7(\varphi_1(x)_1 \cdot \varphi_1(y)_1 + \varphi_1(x)_2 \cdot \varphi_1(y)_2 + \dots + \varphi_1(x)_n \cdot \varphi_1(y)_n)$$

$$+ 3(\varphi_2(x)_1 \cdot \varphi_2(y)_1 + \varphi_2(x)_2 \cdot \varphi_2(y)_2 + \dots + \varphi_2(x)_m \cdot \varphi_2(y)_m)$$

$$= \varphi_3(x) \cdot \varphi_3(y)$$

$$\varphi_3(x) = \sqrt{7}\varphi_1(x)_1, \dots, \sqrt{7}\varphi_1(x)_n, \sqrt{3}\varphi_2(x)_1, \dots, \sqrt{3}\varphi_2(x)_m$$

b. Consider a kernel  $K_1$  and its corresponding mapping  $\varphi_1$  that maps from the lower space  $R^n$  to a higher space  $R^m$  ( $m > n$ ). We know that the data in the higher space  $R^m$ , is separable by a linear classifier with the weights vector  $w$ .

Given a different kernel  $K_2$  and its corresponding mapping  $\varphi_2$ , we create a kernel  $K = 7K_1 + 3K_2$  as in section a above. Can you find a linear classifier in the higher space to which  $\varphi$ , the mapping corresponding to the kernel  $K$ , is mapping?

If YES, find the linear classifier weight vector. If NO, prove why not.

בפתיחה בסעיף a ראינו ש:

$\varphi(x) = (\varphi_1(x)_1, \varphi_1(x)_2, \dots, \varphi_1(x)_{d_1}, \varphi_2(x)_{d_1+1}, \varphi_2(x)_{d_1+2} \dots \varphi_2(x)_{d_2})$   
 בנוסף,  $w$  הוא מפריד לינארי במימד  $m$ , עבור קרנל  $k_1$ . נוסף משקולות בגודל 0 לפי הצורך כלומר נקבל-  $w' = (w_1, w_2, \dots, w_m, 0, 0, \dots, 0)$ ,  $w'$  ודעים שהוא מסווג את המידע נכון עבור  $k_1$ .

ולכן לפי הסעיף הקודם ולפי ההרחבה של  $w$  נקבל את אותו התוצאות (מיפויים) כלומר,  $w'$  הוא מפריד לינארי בדיוק כמו  $w$ .

- c. What is the dimension of the mapping function  $\varphi$  that corresponds to a polynomial kernel  $K(x, y) = (\alpha x \cdot y + \beta)^d, (\alpha, \beta \neq 0)$ , where the lower dimension is  $n$ ?

נפתח בעזרת  $x = (x_1, x_2, \dots, x_n), y = (y_1, y_2, \dots, y_n)$  יש  $n$  כאלה כי המימד שממנו מגיעים הוא  $n$ .

$$K(x, y) = (\alpha(x_1, x_2, \dots, x_n)(y_1, y_2, \dots, y_n) + \beta)^d$$

$$(\alpha x_1 y_1, \alpha x_2 y_2, \dots, \alpha x_n y_n + \beta)^d =$$

כעת יש  $n+1$  מחוברים ולכן, לפי מה שלמדנו בכיתה לפי התאוריה מולטינומית

$$\dim(\varphi) = \binom{d+n+1-1}{n+1-1} = \binom{d+n}{n}$$

- d. Consider the space  $S = \{1, 2, \dots, N\}$  for some finite  $N$  (each instance in the space is a 1- dimension vector and the possible values are  $1, 2, \dots, N$ ) and the function  $f(x, y) = \min(x, y)$ .

Find the mapping  $\varphi$  such that:

$$\varphi(x) \cdot \varphi(y) = 5 \min(x, y)$$

For example, if the instances are  $x = 3, y = 5$ , for some  $N \geq 5$ , then:

$$\varphi(x) \cdot \varphi(y) = \varphi(3) \cdot \varphi(5) = 5 \min(3, 5) = 15$$

נגדיר את המיפוי הבא :

עבור כל מספר  $1 \leq i \leq N$  נגדיר שהמספר יהיה  $i$  פעמים 1 והשאר 0, כלומר עבור  $N=7$  ועבור  $x=3$  נקבל  $(5, 5, 5, 5, 5, 0, 0)$  ועבור  $y=5$  נקבל  $(5, 5, 5, 0, 0, 0, 0)$ .

$N$  יהיה למעשה המימד של  $\varphi$ .

נניח ש  $\min(x, y) = x$  ונסמן

$$n = \sum_{i=1}^x 1.1 + \sum_{i=x+1}^y 0.1 + \sum_{i=y+1}^N 0.0$$

$$\varphi(x) \cdot \varphi(y) = n + n + n + n + n = 5n = 5x = 5(\min(x, y))$$

$$5 \min(3, 5) = 5.3 = 15$$

- e. Consider the space  $S = \{1, 2, \dots, N\}$  for some finite  $N$  (each instance in the space is a 1-dimension vector and the possible values are  $1, 2, \dots, N$ ) and the function  $f(x, y) = \max(x, y)$ .

Prove that the function  $\max(x, y)$  is not a kernel, i.e., there is no mapping  $\phi$  such that:

$$\phi(x) \cdot \phi(y) = \max(x, y)$$

על מנת להוכיח שפונקציה זו היא איננה קרנל, נראה דוגמא לכך שקיים וקטור שעבורו במרחב סופי מסוים המיפוי הוא לא בהחלט חיובי.  
נגדיר:  $S = [1, 2]$   
נסתכל על המטריצה:

$$M = \begin{pmatrix} 2 & 4 \\ 3 & 3 \end{pmatrix}$$

ועל הוקטור:

$$v = \begin{pmatrix} 1 \\ -1 \end{pmatrix}$$

לכן:

$$\langle v, Mv \rangle = \left\langle \begin{pmatrix} 1 \\ -1 \end{pmatrix}, \begin{pmatrix} 2 & 4 \\ 3 & 3 \end{pmatrix} \begin{pmatrix} 1 \\ -1 \end{pmatrix} \right\rangle = \left\langle \begin{pmatrix} 1 \\ -1 \end{pmatrix}, \begin{pmatrix} -2 \\ 0 \end{pmatrix} \right\rangle = 1 * -2 + (-1) * 0 = -2$$

ולכן איננה קרנל.

3. Find the Kernel function for the following mapping. Provide a representation of the form  $\alpha K_1 + \beta K_2$  where both  $K_1$  and  $K_2$  are polynomial kernels and  $\alpha, \beta > 0$ :

$$a. \phi(x) = (x_1^3, x_2^3, \sqrt{3}x_1^2x_2, \sqrt{3}x_2^2x_1, 2\sqrt{3}x_1^2, 2\sqrt{3}x_2^2, 2\sqrt{6}x_1x_2, 4\sqrt{3}x_1, 4\sqrt{3}x_2, 8)$$

$$\begin{aligned} \phi(x) \cdot \phi(y) &= (x_1^3y_1^3 + x_2^3y_2^3 + \sqrt{3}x_1^2x_2\sqrt{3}y_1^2y_2 + \sqrt{3}x_2^2x_1\sqrt{3}y_2^2y_1 + 2\sqrt{3}x_1^2 \cdot 2\sqrt{3}y_1^2 \\ &\quad + 2\sqrt{3}x_2^2 \cdot 2\sqrt{3}y_2^2 + 2\sqrt{6}x_1x_2 \cdot 2\sqrt{6}y_1y_2 + 4\sqrt{3}x_1 \cdot 4\sqrt{3}y_1 + 4\sqrt{3}x_2 \cdot 4\sqrt{3}y_2 + 8 \cdot 8) = \\ &= y_1^3 + x_2^3y_2^3 + 3x_1^2x_2y_1^2y_2 + 3x_1x_2^2y_1y_2^2 + 12x_1^2y_1^2 + 12x_2^2y_2^2 + 24x_1x_2y_1y_2 + 48x_1y_1 \\ &\quad + 48x_2y_2 + 64 \end{aligned}$$

$$= (x \cdot y)^3 + 12(x \cdot y)^2 + 48x \cdot y + 64 = (x \cdot y + 4)^3 = K1$$

$$b. \varphi(x) = (\sqrt{10}x_1^2, \sqrt{10}x_2^2, \sqrt{20}x_1x_2, \sqrt{8}x_1, \sqrt{8}x_2, \sqrt{2})$$

$$\begin{aligned} \varphi(x) \cdot \varphi(y) &= \sqrt{10}x_1^2\sqrt{10}y_1^2 + \sqrt{10}x_2^2\sqrt{10}y_2^2 + \sqrt{20}x_1x_2\sqrt{20}y_1y_2 + \sqrt{8}x_1\sqrt{8}y_1 + \sqrt{8}x_2\sqrt{8}y_2 \\ &\quad + \sqrt{2}\sqrt{2} = \end{aligned}$$

$$= 10x_1^2y_1^2 + 10x_2^2y_2^2 + 20x_1x_2y_1y_2 + 8x_1y_1 + 8x_2y_2 + 2$$

$$= 10(x_1^2y_1^2 + 2x_1x_2y_1y_2 + x_2^2y_2^2) + 8(x_1y_1 + x_2y_2 + \frac{1}{4}) =$$

$$10(xy)^2 + 8\left(xy + \frac{1}{4}\right) = 10K_1 + 8K_2$$

4. The purpose of this exercise is to demonstrate the usefulness of using kernels. Write a Python script that performs the following:
- Draw 20,000 vectors with 20 dimensions.
  - Use the kernel  $(x \cdot y + 1)^2$  to calculate the Gram matrix for these data. That is: each cell  $i,j$  in the matrix is the result of applying the kernel function on the vectors  $i$  and  $j$  ( $i=j$  is also a valid input) :  $KTx_U, x_VW$
  - Find the associated mapping function  $\varphi$ . Into which dimension?
  - Use  $\varphi$  to map the vectors to the higher dimension.
  - Calculate the matrix where each cell  $i,j$  is the result of the dot product of the mapping images of the vectors  $i$  and  $j$ :  $\varphi(x_U) \cdot \varphi(x_VW)$
  - Compare the matrices from sections b and e (use `np.isclose`) – they should be the same.  
\* NOTE: both matrices should be of the same size 20,000x20,000.
  - Compare the time it took your machine to calculate the two matrices. What do you observe?